

agent-Carl-Gustav-Jung · Agent 架构剖析与同类对标

它是怎么设计的、为什么这样设计、好处与代价 —— 兼一路走来的演进

2026-06-11 (v3 修订 · K 战役后)

本报告剖析 agent-Carl-Gustav-Jung 的对话 Agent:重点不在"有哪些功能",而在"每一处为什么这样设计、买到了什么好处、付出了什么代价"。立场为「系统论述 + 诚实评估」——既讲清设计意图与独特性,也不讳言短板。所有技术细节均经源码逐行核实(正文附 文件:行锚点),与同类 Agent 对标处给出 0-5 定性评分(非基准跑分,已注明)。面向自评、协作者与对外说明三类读者。
 v2 修订说明(2026-06-10 晚):当日完成「深度审计(42 子代理对抗核实)→ P0 修复战役(8 切片)→ 检索追平 R1-R4(实测驱动)→ 三轮递进式审查」,15 个 PR 全部合入 main(#23-#38)。本版并入这些变化:初版中"检索体验落后 Claude Code"的多项短板已被实测驱动地补齐(见新增 A.11),0005 等已知 bug 关账,评分表相应更新。初版判断保留处均原文未动。
 v3 修订说明(2026-06-11):完成「研究知识沉淀」K 战役(9 主切片 K1-K8 + 三轮对抗复审 42+36+35 子代理修复 + 跨 repo 活体验证 14 项),agent 仓 PR #40/#42 与 MAGI 仓 PR #34 已合入 main。本版新增 A.12(研究知识层:finding/真伪轴/版本链/群池),工具数 20→22,对标表新增"研究知识沉淀"维度(外部调研确认为全行业空白项)。诚实标注:MAGI 侧代码已合 main 但:8001 运行实例尚未升级部署;群池评审的移动端切换入口为后续项。

摘要

本系统不是一个纯 ReAct 的编码 Agent(逐步"想一步做一步、改文件跑 shell"),而是一个后台可恢复、记忆分层、支持群聊多人、可自我改进的对话 Agent。它的核心设计取向是把 Agent 的每一步落库为单一真相、用独立 worker 在 PostgreSQL 队列上可被另一进程接管续跑,并用一次规划 + 续跑重规划(plan-once + continuation-replan)而非纯逐步 ReAct 来换取成本、延迟与可恢复性。

双结论:立意与工程已落地且自洽——后台可恢复、双层记忆、控制面(中途改向 / 审批 / 暂停问人)、角色化子 Agent、MCP 双 transport、自我改进闭环均已实现并测试;代价也真实——对高度探索性的任务,plan-once 不如逐步 ReAct(故保留 M2 作为可选 flag);执行面刻意收窄(无 shell / 文件系统 / 浏览器);生态/通用子 Agent 不及 Claude Code 一类。

v2 增量结论:检索子系统经当日 R1-R4 实测驱动升级后,「检索 agentic 体验」已不再是初版所述的全面短板——中英双语并行扇出、结果质量信号(垃圾识别 + 自动改写查询)、结构化检索记忆、可溯源 [n] 引用均已落地并经真实 query 活体验证(A.11);plan-once 与纯 ReAct 的差距被 refine 门部分补位,但"逐步重想"的终态差距仍在(M2 flag 不变)。

v3 增量结论:K

战役补上了此前最大的结构性缺口——研究产物的长期沉淀与再检索(此前查过的论文/结论在 run 结束后即不可再查:引用清单有库无读、蒸馏不含 URL、无显式写记忆工具)。现在:研究 run 收尾自动把「结论+出处」蒸成 finding 写入 MAGI 情景层(三轴正交:评审 status / 时效 valid_until /

真伪 truth_status,伪≠删——已证伪结论仍可查但带警示);save_memory 让"记住 X"不再落空;prior_research 开局预取让后续研究站在已有结论的肩膀上;deep_research 报告自动存档可读回;纠错全程可逆且留版本链。外部对标调研确认"研究知识库"为全行业空白(Codex 显式排除外部检索内容进记忆、ChatGPT Deep Research 报告不可复访)——这是本项目当前最独特的差异化能力(A.12)。

术语对照

中文	代码标识	含义
一次规划 + 续跑重规划	plan-once + continuation-replan	先生成整条 plan 再执行,plan 跑完且未达标时由反思决定是否带进展续跑(非逐步 ReAct)
运行 / 子运行	agent_run / parentRunId	一次 Agent 任务;子运行由 deep_research/spawn_subagent 派生
步骤	agent_step	落库的最小单元(plan/tool_call/observe/reply/replan/approval_*/steer...),append-only
中途改向	steer	用户在运行中插话改变方向
审批门	approvalMode	工具级:auto 自动 / ask 需批准 / never 执行期硬拒
反思	reflection	收尾单点裁决"目标达成没、要不要续跑"
情景记忆	episodic / MAGI 层	外部 MAGI 服务的按需召回记忆(向量 + 时序失效)
核心记忆	memory_fragments	原生 always-on 稳定身份/偏好记忆
角色	AgentRole	子 Agent 的能力档:generalist/researcher/analyst
群聊协调	topicCoord	同 topic 多人触发时的 合并/排队/新建决策
技能	topic_skill	注入 system prompt 的"群规";可由任务收尾自动蒸馏
质量信号	SearchQuality	检索输出的机器可读质量档:ok / low_relevance(全为低分垃圾) / fallback_loose(宽匹配需核对) / empty
查询扇出	queries[] / tasks[]	一步并行发多查询变体 / 并行派多个子研究员(工具 handler 内 Promise.all,主循环零侵入)
refine 门	low_signal_search	近 4 步内 ≥2 步垃圾/空搜索 → 自动重规划改写查询(每 run 一次,防死循环)
引用标记	[n] + filterCitedRefs	终稿关键论断标注资源序号;资源清单只保留真被引用的 url(产物类恒保留)
研究结论	finding + sources	v3:带出处的单条 claim(kind='finding',sources=[{url,title,year}]),收尾自动蒸馏或 save_memory 显式写入

中文	代码标识	含义
真伪轴	truth_status	v3:unverified/disputed/refuted,与评审轴(status)、时效轴(valid_until)三轴正交;伪≠删,可查但带【已证伪】警示
版本链	superseded_by_id	v3:旧记忆被取代时记下新条id;行永不物理删除,删错可循链追回
群共享池	group:{groupid}	v3:群聊 run 的 findings 落群伪owner,成员互见;个人 facts 永远私有
开局预取	prior_research	v3:父 run 首次规划前自动检索相关 findings 注入 planner(top5/score≥0.6/800ms fail-open)

Part A · Agent 是怎么设计的(核心)

本部分占全文重心。每个子系统按 设计 → 为什么这样(好处)→ 权衡/代价 三段展开。

A.1 总体设计哲学

四条贯穿全局的原则:

- 1. 单一真相落库:每一步(规划、工具调用、观察、回复、改向、审批)都 append-only 写入 agent_steps;运行级状态写 agent_runs。内存态从不作权威。
- 2. 后台可恢复:运行不绑定某个进程或某个 HTTP 连接;独立 worker 从 PG 队列捡活,崩溃后可被另一 worker 接管续跑。
- 3. fail-open(失败不致命):记忆写入、技能蒸馏、MCP 注册等"增益型"环节任何失败都不影响主任务收尾。
- 4. 持久化优于内存态:凡需跨步/跨续跑存活的状态(改向指令、被拒工具、检查点)一律落 run 级列,而非进程内变量。




图 1

好处:这套"落库 + worker 队列"让 Agent 天然具备 *会话级 Agent 做不到* 的能力——关掉 App、换设备、服务重启,任务都还在跑且永续。代价:比"进程内一把梭"的会话 Agent 多了 DB 往返与状态机复杂度;但对一个要长期陪伴、跑长任务的助理型 Agent,这是值得的地基。

A.2 为什么是 plan-once + continuation-replan,而非纯 ReAct

设计:buildInitialPlan(runPlanGlue.ts)用一次 LLM 调用生成整条 JSON

plan(planner.ts:generatePlanWithLlm,无 LLM/测试环境退化为 echo 桩);runExecute.ts 顺序执行 plan 的每一步;plan 跑完若 todo 未尽且预算未耗,由 reflection.ts

单点裁决是否带"已完成进展"续跑重规划。续跑硬上限 CONTINUATION_ROUND_CAP =

2(runExecute.ts,行号随版本漂移不再钉)+ 无新进展的 stall guard。




图 2

为什么这样(好处):① 省 token/延迟——一次规划胜过逐步多轮"想-做"往返;② 可后台可恢复——一条确定的 plan 落库后,worker 接管续跑天然成立(纯 ReAct 的"下一步全凭上一轮"难以干净恢复);③ 收尾有单点裁决——reflection 集中判断"达标没",避免逐步 ReAct 常见的"不知何时停"。

权衡/代价:对高度探索性任务(下一步强依赖上一步观察),一次规划不如逐步 ReAct 灵活。系统的补偿是 continuation-replan(带进展重规划)+ steer(用户改向),但终究不是纯 ReAct。这正是 M2 路线图保留"mode flag,plan_once↔react 共存"的原因——prototype 已测延迟,达标再 opt-in,不替换核心循环。

A.3 worker 队列与心跳接管 —— 最大差异化好处

设计:worker.ts 每 ~2s 一个 tick:用 pg_advisory_xact_lock 在事务内取 topic 槽位、pickupNextRun 捡 draft/running/replanning/queued 的运行、executeRun 异步派发(不 await);心跳戳

lastHeartbeatAt,崩溃后该 run 可被另一 worker 接管。每个 tick 还顺手:审批超时自动裁决、ask_user 24h 超时取消、群聊 ask_user 30s 升级全员可答。




图 3

好处:崩溃/重启/扩容都不丢任务——这是把 Agent 从"会话玩具"变成"可托付的后台执行体"的关键。代价:需要幂等与 reclaim 配套(见 A.8),否则接管会重复副作用。

A.4 工具层:元数据驱动的安全与幂等

设计:toolRegistry 注册 22 个生产工具(registerAgentTools.ts;v3 +save_memory/read_document)。每个 ToolDef 带元数据:approvalMode(auto/ask/never)、costHint(low/medium/high)、hasSideEffects、id empotent、可选 computeIdempotencyKey。

工具	类别	approvalMode	幂等
search_papers / get_paper_citations / search_web / wikipedia / fetch_url / document_reader	只读检索(v2:带质量信号 + 扇出)	auto	
get_economic_series / magi_system_read	只读数据/知识库	auto	
datetime_now	当前时间	auto	(时间天然变化)
youtube_transcript	只读检索	auto	
recall_memory / recall_step	记忆召回(v3:recall 带出处/真伪标/群聊双池)	auto	
save_memory	显式写长期记忆(v3:fact 走 reconcile 版本链/finding 带出处)	auto	
read_document	读回写作区文档/存档研究报 告(v3)	auto	

工具	类别	approvalMode	幂等
critique_last_answer	元思自检	auto	
render_diagram	计算/出图	auto	
run_python	E2B 沙箱计算(副作用)	auto(护栏=沙箱隔离+预算, 非审批门)	
doc_export_markdown	导出到私有文档库	auto	(按 title upsert)
magi_content_ingest	写入外部知识库	ask	
ask_user	暂停问人	auto	
deep_research / spawn_subagent	派子 agent	auto	

为什么这样(好处):① 审批分级——对外部系统写入(magi_content_ingest)与 MCP 远端工具默认 ask,只读检索 auto;沙箱 run_python 实为 auto,护栏是 E2B 隔离+预算而非审批门(顶层与子 agent 同权,见 Part F 诘问三);② 幂等键 + 唯一索引(agent_steps(run_id, tool_call_key),key 含 ownerId 名空间)——同一工具同参在一个 run 内恰好执行一次;命中缓存则写一条 observe 步留痕而不重复调用;③ 配合 reclaim,崩溃接管不会重复发邮件/重复写库这类副作用。

权衡:approvalMode 是工具级声明(并非独立的审批服务),never 走的是执行期硬守卫而非审批门——简单但意味着"审批策略"分散在各工具定义里。

A.5 控制面:中途改向与审批拒绝(本会话重点重构)

设计:运行进行中,用户可 steer(改向)、对 ask 工具 approve/deny、被 ask_user 暂停后 resume。本会话把 steer/deny 的重规划从早期"echo 占位桩"升级为真 LLM 重规划 + 持久化:

- steer:清 plan + 置 replanning + 把改向指令写入持久列 agent_runs.steer_directive(迁移 024);worker 接管时 buildInitialPlan 读它喂 LLM 重规划。
- deny:被拒工具名 append 进持久列 agent_runs.denied_tools(迁移 025);buildInitialPlan 每次都注入"不要调用 X";并在执行期加硬门(runExecute.ts 在 dispatch 前跳过被拒工具)。





图 4

为什么这样(好处):早期 echo 占位桩的毛病是"接受了 steer 却不真改向 / deny 后工具又被重新规划"。持久列让改向/避坑跨多轮续跑不漂回原主题;软 prompt + 硬执行门双层确保即便 LLM 无视提示重拟被拒工具,执行期也兜底跳过、不会再撞审批门陷入循环。本会话以真模型活体验证:steer「改讲共时性」后终稿主题词频从持久化前的"共时性 1 / 个体化 5"变为"共时性 11 / 个体化 0"。

权衡:持久列目前只增不清(到 run 结束才失效)——对评审型场景刻意保持 focus-refresh 的新鲜度而非省调用(详见 Part C)。

v2 新增 · 未知工具名优雅 replan(issue 0005 关账):LLM 幻造工具名时,parse 期 `parsePlannerJsonDetailed` 区分「JSON 坏」与「未知工具名」,后者带原因同会话重试一次("工具 X 不存在,只能用列表内 name");二次仍未知才 failed 终态(不再静默 echo 降级,错误对用户可见)。exec 期(缓存/陈旧 plan 漏网)记 `tool_Error` + replan 一次,按 `toolName` 计数(别的工具的历史重试不连坐)。配套:所有 replan 路径统一在 `applyReplanningIfNeeded` 咽喉累积 checkpoint(P0-S5)——steer/deny/critique 重规划不再丢早期发现、不重复搜索;`completedTodos` 跨轮并集(P0-S6),round2 不重做 round1 完成项。

A.6 子 Agent:角色化最小权限

设计(M3):`deep_research` 与 `spawn_subagent` 派生子运行(`parentRunId`),由独立 `childExecutor` 池跑。子 Agent 按 `AgentRole(types.ts:3:generalist/researcher/analyst)` 获取工具子集
`SUBAGENT_ROLE_TOOLS:researcher` 是 10 个只读工具(9 检索 + v3 `recall_memory`,子研究员开局先查已沉淀 findings 再往外搜);`analyst` 额外加 `run_python` + `render_diagram`。




图 5

为什么这样(好处):① 最小权限——子 Agent 只拿任务所需工具,`analyst` 才碰沙箱 `run_python`,安全面收敛;② 双检——`planner` 裁剪工具列表 + 执行期再守卫一遍(防缓存/续跑 plan 绕过 `planner`);③ 防递归——任何角色子集都不含 `deep_research/spawn_subagent/ask_user`,子 Agent 无法再派子 Agent 或暂停。

权衡:`deep_research` 现等价于 `spawn_subagent(researcher)`,两个工具对 `planner` 略有重叠(已记入 backlog,加第 4 个角色前重访)。

v2 新增 · 并行派研究员 + 深度守卫:`spawn_subagent` 支持 `tasks[(2-5)]`——一步并行派多个研究员各查一个独立角度(如 历史脉络/当代研究/批评观点),`lead` 聚合分节报告 + 引用按 `kind:id` 去重;并行在工具 handler 内 `Promise.all` 完成,主循环的审批/幂等/记账不变(决策:不动主循环的十余个串行不变量)。防递归从两道升到三道:工具 handler 检查 + 角色白名单不含 `spawn` 类 + `runChildSubagent`

入口深度守卫(P0-S8,红测试证实绕过调用方时此前真会建出孙 run 并空轮询到超时)。

A.7 双层记忆:稳定核心 + 按需情景

设计:① 原生核心 `memory_fragments`——always-on 注入 system prompt
的稳定身份/偏好/项目记忆(autoExtract 抽取、consolidate 合并、promote 升格;三 scope
user/session/topic;解析端 0.55 置信门——prompt 指引"明确『记住』 ≥ 0.85 "但非代码强制;0.85
阈值实际生效处是 MAGI 情景层的 approved/pending 质量门);② MAGI 情景层——外部 MAGI
服务(integrations/magi.ts $\rightarrow$ /api/agent-memory/*):bge 向量 +
稀疏混合检索、时序失效(invalidate)、质量门、主动召回 + `recall_memory` 工具按需召回。




图 6

为什么这样(好处):稳定的"你是谁"常驻不耗检索;海量"聊过什么"按需召回不撑爆上下文;时序失效让"我改主意了"能覆盖旧事实;升格让反复出现的情景事实沉淀为核心。代价:依赖外部 MAGI 服务可用(未启用则 fail-open 返空);两层的一致性靠 owner 隔离 + 升格补偿维持。

v3 扩展:情景层从 fact/insight 两类扩为三类——新增 finding(带出处的研究结论),并补齐纠错/恢复/真伪/版本链全套生命周期,详见 A.12。

A.8 韧性:分布式下副作用恰好一次

设计:幂等键(resolveToolCallKey,含 ownerId 名空间)+ `agent_steps` 唯一索引;命中则写 `observe`
缓存步;reclaim 检测(DB 已落 step 数 > `usage.steps`→补记 reclaim,接管不重复);E2B 沙箱按
`run.sandboxId` acquire/重连/失败新建,收尾 best-effort kill。

好处:多 worker 并发 + 崩溃接管下,带副作用的工具恰好一次;沙箱跨步持久(`run_python`
多次调用复用同一沙箱),终态回收。代价:沙箱超时回收后重连失败需新建,偶有冷启动延迟。

A.9 群聊协调:多人同 topic 不打架

设计(M7):`topicCoord.ts` 用 advisory lock 在事务内决策——子运行/私聊/无阻塞→新建;阻塞者同 owner 或 30s 窗口内(`MERGE_WINDOW_MS=30_000`)→合并(追问 append 进 `mergedInputs`);否则→排队。




图 7

好处:群里多人几乎同时 @ 同一话题,不会起多个打架的 run,也不丢任何人的追问。代价:合并窗口是经验值(30s),跨人长间隔仍排队。

A.10 自我改进闭环

设计(M1/M5):成功的多步任务收尾时,自动把"这类任务怎么做"蒸馏成一条 `topic_skill(source=auto_distilled、enabled=false` 待评审);情景记忆可升格为核心;mobile 大脑 tab 提供技能/记忆/情景三个评审屏 + hub 待审 badge(本会话 #20)显示"N 条待审"。

好处:用得越久越懂你(技能/记忆沉淀),且人在环路——自蒸馏默认不启用,经用户评审才生效,防注入/污染。代价:需要用户去评审(故 #20 加 badge 提升发现性);技能注入有 prompt-injection 防御(high severity 拒、low warn)。

A.11 检索管线(v2 新增:R1-R4,实测驱动)

本节是 v2 的核心增量。方法论先于内容:每一项改动都来自真实 query 的实测观察,而非设计推演——开工前先拿真 Tavily/OpenAlex/DeepSeek 探针复现失败,被实测推翻的假设(OpenAlex 中文学术弱、wikipedia 中文坏、detailLevel 分页、token 统账重构)直接砍掉不做。

设计:六层升级,自检索发起到终稿引用首尾贯通——

1. 双语检索,汉化只在收尾:planner

检索战法要求研究/事实类任务对同一主题出中文+英文两路查询(外文语料更全);REPLY_SYSTEM 在收尾统一中文转述,专有名词/论文标题保留原文。活体验证:真 DeepSeek 对「研究共时性学术依据」自动生成 "Jung synchronicity empirical evidence" + "荣格 共时性 实证" 双路,并自发选用英文维基。

2. 工具配置榨干 provider(R1):Tavily `include_answer` 概括透传(实测中文质量好)、`snippet` 300→1000(实测正文常返 1200-2400 字,截 300 丢 75% 已付费内容)、`searchDepth` 参数开放(advanced 实测多出学术源,LLM 无提示自发用于深查询)。

3. 质量信号(R1-2):实测发现生造词 query 不返 0 条,而是 5 条 `score<0.2` 的不相关垃圾,Tavily answer 还会一本正经编造解释——"搜错"比"搜不到"更隐蔽。实测 `score` 双峰分布(垃圾 0.03-0.17 / 正经 0.72-0.87)→ `score` 逐条透传;全低分标 `low_relevance` + 丢弃幻觉 answer;混合时滤除垃圾条目;OpenAlex 严格匹配 0 → CrossRef 宽匹配结果标 `fallback_loose` 警示核对。低质输出不产生正式引用(extractRefs 看 quality)。

4. 结构化检索记忆(R2):checkpoint finding 从"只存 top-5 标题"升级为「title (year) — url + snippet 摘录」,质量警示 置顶——重规划时大脑看得见"搜到什么、去哪深读、该不该信";progress 摘要同步结构化(替换碎在 snippet 中间的 200 字 JSON 截断)。

5. refine 门(R2-3):近 4 步内 ≥2 步垃圾/空搜索 → critique 触发重规划,理由明示「换关键词/换语言」;每 run 只触发一次(结构化 `gate` 字段防呆),之后靠 budget/stall guard 兜底——以 ~10% 的改动拿到纯 ReAct"看结果改查询"的主要收益。

6. 并行扇出 + 可溯源引用(R3/R4):`search_web_queries[]` 单步并行中英双路(活体:2.7s 合并去重 8 条,matchedQueries 标注命中来源);`spawn_subagent tasks[]` 并行派研究员;终稿关键论断标 [n],资源清单经 `filterCitedRefs` 只保留真被引用的 url(无标记/越界 fail-open,文档/图等产物恒保留)。

为什么这样(好处):① 检索面覆盖中英两个语料世界,而成本只多并行的一次调用;② 垃圾结果从"无声混入大脑并被引用"变为"被识别、被滤除、触发改写"——三道关(quality 信号 → 引用层拦截 → refine 门);③ 重规划的决策素材完整(结构化记忆),多跳检索不重做、不瞎做;④ 终稿引用可逐条溯源,清单不被搜索 ref 灌满。

权衡/代价:① 质量阈值 0.3 来自当日实测分布,Tavily 评分漂移需重标定(常量集中,一处可调);② refine 门每 run 一次是保守取舍——换词后仍垃圾时不再二次触发,靠预算兜底;③ 扇出 answer 各答各题故多查询模式不透传概括;④ 纯 ReAct 的"每步重想"终态差距仍在,M2 flag 保留。

质量保障:本节全部改动经三轮递进审查(medium → 7 角度合并审 → xhigh 9 角度 + sweep + CONFIRMED 逐条对抗反驳);xhigh 轮首批 12 条 CONFIRMED 被对抗复核击杀 9 条,存活 3 条(垃圾进引用/警示静默丢失/空白 title 穿透)全部修复——"问题必须真实可触发"作为核实硬标准。

A.12 研究知识沉淀(v3 新增:K 战役)

立项动机来自外部对标调研:研究产物(查过的文献+引用+结论)的结构化长期沉淀是全行业空白——Codex 的 memories 显式排除用过 web search/MCP 的线程;ChatGPT Deep Research

报告不可复访是社区头号抱怨;Hermes 只把洞察蒸进有界记忆不存引用。而本项目 MAGI 情景层的 pgvector+jieba 混合检索、0.85 质量门、评审 UI 正好是现成地基——不建第四个记忆系统,给情景层加一个 provenance 维度。

北极星:今天查过并引用的论文,明天新会话问起,agent 能召回结论并给出原始 URL。

设计:七件事首尾闭环——

1. 引用链修复(K1):子 run 引用回流原读一个全仓无写入方的字段(恒空死路径),改读子 run artifact.refs(终稿真引用,url 类,≤10 防洪);deep_research/spawn_subagent/document_reader 补 extractRef(s),来源 URL 进父 run 资源清单;子报告 [n]

标记按子清单编号,进父上下文前剥离防错引;复审另发现并修复 checkpoint

回归——合成报告引用全与早先深读重叠时会被去重规则整条吞掉,新增 synthesis 发现类豁免。

2. finding 数据模型(K2/K3,跨 repo):MAGI agent_memory_fragment 表 kind 扩 finding + sources JSONB([url,title,year]),source 标题拼进 search_vector——"Kahneman 1992"走 sparse 路精确命中)+ 三轴正交:status(评审:pending/approved/rejected)、valid_until(时效)、truth_status(真伪:unverified/disputed/refuted + truth_note + counter_sources 反证)。伪≠删:search 不按真伪过滤,已证伪结论照常命中、渲染带【已证伪】+反证——"记得它是伪的"本身是知识。decide 放宽为 approve/reject 双向互转(approved 错误记忆可标错、rejected 可恢复;已升格行 MAGI 裸端点 no-op——由面板层自动 unpromote 后重试补偿,见第 7 条);revalidate 恢复误失效;invalidate 带 superseded_by_id 写版本链。行永不物理删除。

3. 研究蒸馏(K5,自动化主干):completed 父 run 收尾,独立第二次 LLM 调用把「终稿+编号 refs 清单」蒸成 ≤4 条 finding。反幻觉:LLM 只输出 sourceidx 指向编号清单,代码侧映射 idx→source,越界/无出处整条丢弃(LLM 永远不写 URL)。近邻 ≥0.92 同源机械去重;≥0.85 跑争议判官(duplicate 跳过/contradicts 写新+旧条标 disputed 带反证/distinct 并存)——机器只升到 disputed,refuted 由人裁决(证据保全)。

4. save_memory 工具(K4):修"run 中说记住 X 落空"——fact 路径走 reconcile(「其实 X 是 Y」自动取代旧条留版本链);finding 路径(带 source_url)机械近重;每 run 5 次硬上限+幂等键 sha256(全文+url);永远写 MAGI(agent 自主写 always-on 核心 = 自我提示注入通道,不开)。

5. 召回与开局复利(K6):recall_memory 命中带出处与真伪标;prior_research 预取——父 run 首次规划前自动检索相关 findings 注入 planner(800ms fail-open),"站在之前研究肩膀上"的强制落点;子研究员工具集补 recall_memory。

6. 归属两轴(修订三):个人 facts 永远私有;群聊 run 的 findings 进 group:{groupid} 共享池——家人在群里问"我们之前查过 X 吗"能命中任何成员触发过的研究;读侧双池归并收口在 memoryPools.ts,群聊个人池强制 findings-only(隐私底线)。

7. 报告复访(K7)+ 评审闭环(K8):deep_research 报告自动存档写作区(《研究报告:…》,同名 v2 版本化保护)+ read_document 读回;大脑 tab

评审屏:真伪徽标/可点来源/「查看来源任务」深链(回溯三层:论文 URL → 原始 run → 存档报告)/标错-恢复-标伪-撤销全可逆;复审修复:恢复同时处理时效轴(先 revalidate 再按需 decide)、已升格记忆可标错(面板层自动 unpromote 解锁后 reject;promote 时复制进原生核心的副本无反向链接,需在长期记忆页手动删除——已知残余)、【已失效】标让死记忆可见。

为什么这样(好处):① 研究知识形成复利——后续 run 开局即知"上次查到哪",不重搜、可续深;②

知识可信——出处可点、真伪有标、冲突共存不销毁证据;③

纠错灵活且安全——三轴全可逆、行不删、版本链可循;④ 全部复用已验证基建(检索/质量门/评审 UI/owner 隔离),净新增持久化设施 = 一个枚举值 + 五列。

权衡/代价:① 每研究 run 多一次蒸馏 LLM 调用(refs 非空才发起,家庭规模每天几次);② finding 文本进向量库的信噪比依赖 0.85 质量门+近重门+预取 0.6 阈值,需长期观察(claim 截 300 字、URL 不进 text 已预留 fallback);③ 注入残余面与既有 proactive recall 同源(web 衍生文本进 prompt),纵深防御为蒸馏 prompt 反指令守卫、save_memory 描述明示、写入侧长度帽(蒸馏 claim≤300/save_memory text≤500/title≤300/note≤1000)、http(s) 白名单、人审通路——家庭信任域内接受;④ 群池仅 findings 可共享,评审的移动端群池切换入口为后续项(后端+客户端链路已就位并测试)。

质量保障:三轮对抗复审(42/36/35 子代理)CONFIRMED 全修;跨 repo finding 全生命周期(写带出处→语义+标题词双路检索→标伪仍可查→版本链→失效/恢复)以真实 agent 端客户端 ↔ 活体 MAGI 容器在隔离库上验证 14 项全过。部署门(诚实):MAGI 侧已合 main,但 :8001 运行实例尚未升级(活进程跑旧代码且容器缺 jieba,直接重启会崩——需重建镜像+迁移+重启);完整"真 agent run→蒸馏→跨会话召回"活体回归待部署后执行。

Part B · 与常见 Agent 对标

B.1 物种之辨

参照系两阵营:个人助理型(Hermes、OpenClaw:持久分层记忆 + 技能/自我改进 + soul + 常驻)与编码 Agent(Claude Code、Codex、Cursor:纯 ReAct + 文件/shell/代码工具 + plan mode)。本项目偏个人助理型,但叠加了编码 Agent 少见的后台可恢复 + 群聊多人。

B.2 述要

- Hermes / OpenClaw:常驻进程、分层记忆、技能模板、宽执行面(shell/文件/浏览器)。
- Claude Code / Codex / Cursor:会话级纯 ReAct,强在代码库内文件/shell/多文件编辑、通用子代理、MCP 客户端+服务端、用户可配 hooks。

B.3 能力对比

维度	本项目	Hermes	OpenClaw	Claude Code	Codex	Cursor
Agent 循环	plan-once+续跑(ReAct 留 flag)	ReAct	ReAct	纯 ReAct	纯 ReAct	纯 ReAct
后台/可恢复	PG 队列+心跳+幂等(强)	常驻	常驻	会话级	会话级	会话级
记忆分层	核心+情景两层(强)	5 层	SOUL+记忆	CLAUDE.md	AGENTS.md	规则/索引
自我改进/技能	自蒸馏+评审			skills	—	—
群聊多人	topic 合并/排队(罕见)	—	—	—	—	—

维度	本项目	Hermes	OpenClaw	Claude Code	Codex	Cursor
检索体验(扇出/质量信号/引用)	v2:双语扇出+score 质量门+[n] 溯源	弱	弱	强	中	中
研究知识沉淀(结论+出处+真伪可再查)	v3:finding/ 真伪轴/版本链/群池(全行业空白项)	蒸馏洞察不存引用	—	—(memory不存研究产物)	—(显式排除外部检索内容)	—
执行面宽度	web/文档/M AGI/沙箱 Python(无 shell/文件)	宽	宽	文件/shell	沙箱	代码库
通用子 agent	角色化(researcher/analyst)	—	—	通用	—	—
MCP	client(stdio+http)	—	插件	c/s	工具	工具
审批/沙箱	auto/ask/never+沙箱	—	权限			—

注:竞品列的能力描述为外部对标调研结论(截至2026-06,来源含官方文档/仓库),非源码核实;「本项目」列经源码核实。

B.4 定位

在「后台可恢复 + 记忆分层 + 群聊多人」象限领先多数编码 Agent;v2 后「检索 agentic 体验」从落后项转为接近追平;v3 后「研究知识沉淀」成为独有维度——外部调研确认头部产品均未做"查过的文献+结论+真伪"的结构化沉淀与再检索,这与"研究知识越积越强"的产品愿景直接对齐;仍落后处为「纯 ReAct 终态、执行面宽度(无 shell/文件/浏览器,刻意)、通用子 Agent 与生态」。

B.5 功能评分(0-5,定性,非基准)

维度(↑越好)	本项目	Hermes	Claude Code	Codex	Cursor
后台可恢复	5	4	1	1	1
记忆分层/长期	5	5	2	2	2
群聊多人协调	5	1	0	0	0
自我改进/技能	4	5	3	1	1
控制面(改向/审批/暂停)	4	2	4	4	3
检索体验(扇出/质量/引用)	4(v2,原≈2)	2	5	4	3
研究知识沉淀(v3 新增维度)	5(独有)	2	1	0	1
子 agent 通用性	4(v2:tasks[] 并行,原 3)	1	5	1	1

维度(↑越好)	本项目	Hermes	Claude Code	Codex	Cursor
执行面宽度	2	5	5	4	4
编码/文件/shell	1	4	5	5	5
上手/生态	2	3	5	4	5
MCP/可扩展	3	1	5	3	3

评析:本项目在后台可恢复 / 记忆分层 / 群聊上独占高分(竞品多为 0-1);v2 后检索体验升至 4(与 Codex 持平、距 Claude Code 一档,差在纯 ReAct 逐步重想与浏览器执行面)、子 agent 通用性升至 4(tasks[] 并行派研究员);仍在编码/文件/shell / 上手/生态上垫底——这是定位选择(对话陪伴型,非编码 Agent)的直接结果,非缺陷。

Part C · 现状、局限与逐设计 review

已落地:Part A 全部子系统 + M1(自蒸馏)/M3(子 agent)/M4(MCP)/M5(评审)/M7(群聊)+ 上午 7 个已合 PR + v2:P0 修复战役 8 切片与检索追平 R1-R4 共 15 个 PR(#23-#38)全部合入 main + v3:K 战役(研究知识沉淀)agent 仓 PR #40/#42 + MAGI 仓 PR #34 合入 main。

未竟:M2 ReAct 全量(仅 prototype);群池评审移动端切换入口(后端+客户端已就位);MAGI :8001 实例升级部署与其后的全链活体回归。

v2 关账项:issue 0005(未知工具名悬挂)已修——原始"永停 planning"复现在审计时已不成立(文档滞后于代码),残余的优雅 replan 路径于 P0-S4 落地,验收四条全过;测试体系两档分层(P0-S1):此前 62/117 个测试文件无 DATABASE_URL 全红、另有静默假绿,现无 PG 显式 skip / 有 PG 全绿 + test:pg fail-fast。

逐设计的诚实 review(代价):

- plan-once:省 token、可恢复,但探索性任务弱于逐步 ReAct → 靠续跑 + steer 补,终非纯 ReAct。
- 续跑 CONTINUATION_ROUND_CAP=2:防失控,但极复杂任务可能 2 轮不够 → 由 budget 兜底而非无限续。
- 持久列只增不清:steer_directive/denied_tools 注入到 run 结束;对评审 hub 刻意不加 TTL(freshness > 省调用:用户批准后返回必须看到更新计数)。
- 子 run 轮询:runChildSubagent 每 500ms 轮询 DB(至多 5min),未走 event-bus → 低负载无感,上规模是 DB 压力(backlog)。
- zenmux 已实现待实战:zenmux 适配器完整(双协议路由+用户 key 通道,spike 实测打通),但日常活体运行仅 DeepSeek 长期验证。
- 执行面刻意收窄:无 shell/文件/浏览器——安全 + 聚焦,但也意味着不做代码 Agent 的活。
- (v3)蒸馏成本与信噪比:每研究 run 多一次 finding 蒸馏调用;finding 进向量库的长期信噪比待真实使用观察(0.85 门+近重+0.6 预取阈值三道闸,fallback 已预留)。
- (v3)部署滞后于代码:MAGI 侧 finding 端点已合 main,但 :8001 活进程是 M4 前旧代码且容器缺 jieba——重启即崩,升级需"重建镜像+alembic 迁移+重启"三步;在此之前线上 agent 实际不写不读 finding(各写入方 fail-open 降级)。

可证伪评测设计:① 记忆——A run 写事实、新 session B run `recall_memory` 跨会话召回 + 时序失效覆盖改口(本会话已活体验证);② 续跑——多步任务 plan 跑完未达标须续跑且 2 轮内收敛;③ 子 agent——researcher 子 run 试调 `run_python` 必被执行期守卫拒、analyst 放行(已单测);④ steer——改向后终稿主题词频应翻转(已活体验证)。

Part D · 路线图与"明确不做"



图 8

- 优先:M2 ReAct opt-in 共存(prototype 已测,需架构决策,专门推进)。
- backlog(低优):子 run 等待改 event-bus、count 端点(避免拉全列表计数)、deep_research↔spawn_subagent 重叠、search_papers 扇出(planner 已能分两步双语查,单步省一步的边际收益待真实使用观察);v3 新增:群池评审移动端切换入口、MAGI :8001 升级部署 + 全链活体回归、finding 信噪比长期观察(劣化则启用 text 去 URL fallback)。
- 明确不做:shell / 文件系统 / 浏览器——刻意收窄执行面以保安全与聚焦。v2 按实测原则追加砍掉:fetch/document detailLevel 分页(24K 上限实测够用)、token 统账重构(纯重构无用户可感知收益)、中文学术查询翻译指引(实测 OpenAlex 中文返回 5 篇高相关论文,假设被推翻)。

Part E · 演进史("一路做了什么")

阶段	做了什么
基座	私聊/群聊对话 + 意图体系(<code>agent_run</code> 是被升格的一个意图)
运行时	worker PG 队列 + plan-once 主循环 + planner/reflection
韧性	续跑重规划(epic 0001-0003)+ 幂等 + reclaim + E2B 沙箱
记忆	原生核心 + MAGI 情景双层(向量/时序失效/升格)+ 主动召回
控制面	审批门 + ask_user + steer + budget
群聊(M7)	topic 合并/排队 + 技能三层注入 + 注入防御
自我改进(M1/M5)	任务收尾自蒸馏技能 + episodic→core 升格 + mobile 评审屏/badge
子 agent(M3)	deep_research + 角色化 spawn_subagent + 工具子集守卫
MCP(M4)	stdio + Streamable HTTP/SSE transport + env 配置注册

阶段	做了什么
本会话上午(2026-06-09~10)	steer/deny→M1c LLM 重规划 + 双向持久化 + deny 硬门(#16);M3-S1 角色子 agent(#17);MCP HTTP(#18)+ config(#19);M5 hub badge(#20)+ 渲染测试(#21);终态集合单一源(#22)
v2 · 当日下午~晚	深度审计(42 子代理 + 逐条对抗核实,5 条候选被推翻——文档滞后于代码);P0 修复战役 8 切片(测试两档/0005 关账/replan 统一 checkpoint/completedTodos/引用链/递归守卫);检索追平 R1-R4(实测驱动:双语扇出/质量信号/结构化记忆/refine 门/[n] 引用,详见 A.11);三轮递进式审查(xhigh 轮对抗复核杀 9 留 3 全修);15 PR(#23-#38)全部合入 main
v3 · K 战役(2026-06-10 晚~11)	研究知识沉淀全链:K1 引用链死路径修复(+checkpoint synthesis 回归)→ K2/K3 finding 模型(出处/三轴/版本链,跨 repo)→ K4 save_memory → K5 研究蒸馏(sourceldx 反幻觉+争议判官)→ K6 召回/prior_research 预取/子研究员 recall → K7 报告存档+read_document → K8 评审 UI(真伪徽标/来源深链/纠错追回)→ K9b 复审修复(时效轴恢复/升格可标错);三轮对抗复审(42/36/35)CONFIRMED 全修;跨 repo 活体 14 项全过;PR #40/#42 + MAGI#34 合入 main(详见 A.12)

Part F · 反方与风险

诘问一:plan-once 是否够用? 对探索性任务确实弱。回应(v2 更新):除 continuation-replan + steer 外,refine 门(A.11)补上了"看搜索结果质量中途改写查询"这一 ReAct 的核心收益场景——以 ~10% 改动拿 ~70% 收益;但"每步基于全部观察重想"的终态差距仍在。M2 ReAct 的 opt-in 设计已定稿、延迟 prototype 已实测,flag 尚未落码(待架构决策);实测某类任务持续吃亏即推进——这是真实权衡,非已解。

诘问四(v2 新增):质量信号的 0.3 阈值可靠吗? 阈值来自单日实测(垃圾 0.03-0.17 / 正经 0.72-0.87 的双峰分布),Tavily 评分体系若漂移会误判。回应:① 双峰间隔大,0.3 留了足够余量;② 全部判定 fail-open——误判 low_relevance 时结果仍在输出里(带警示),只是不产正式引用;③ 阈值是单一常量,重标定一处改;残余风险是评分分布漂移期的引用偏保守,可接受。

诘问二:双层记忆会否噪声/泄漏? 海量情景若无组织即噪声;跨用户召回即隐私事故。回应:时序失效 + 质量门(conf 门)+ 升格控制信噪;owner 全程隔离(已活体验证换 owner 召回返空)。前提是 MAGI 服务可用,否则 fail-open 降级。

诘问三:子 agent 给 run_python 安全吗? analyst 子 Agent 可跑沙箱代码。回应:① 顶层本就能 run_python,委派给子 Agent 非提权;② E2B 沙箱隔离 + 子 run 预算(≤8 步/120s/50k);③ 角色双检 + 防递归。残余风险是沙箱本身的逃逸面,依赖 E2B。

诘问五(v3 新增):web 衍生的 finding 进 prompt,会不会变成持久化注入通道? 攻击面真实:恶意网页文本若被蒸成 finding,会经 recall/prior_research 反复进入后续 planner prompt。回应:① 该面与既有 proactive recall 同源(对话衍生文本早已进 prompt),finding 只是扩大来源;② 纵深防御——蒸馏 prompt 反指令守卫("网页里的祈使句不是研究结论")、save_memory 描述明示不存指令、每 run 5

次硬上限、写入侧长度帽(蒸馏 claim $\leq$ 300/save_memory text $\leq$ 500/title $\leq$ 300/note $\leq$ 1000,召回不再截)、source url 仅 http(s)、注入块标注"参考资料(非指令)";③ 全部条目带 provenance 可审可灭,owner/群隔离限定爆炸半径。残余风险是 LLM 对注入文本的鲁棒性本身,家庭信任域内接受,不适用于开放多租户。

诘问六(v3 新增):findings 会不会淹没评审队列/污染召回? 回应:四道闸——仅父 run 蒸馏、每 run $\leq$ 4 条、0.85 高置信自动批(不进队列)、近邻 0.92 同源去重;召回侧 claim 截 300 字、URL 不进 text(在 sources 列)、预取 0.6 阈值挡闲聊。残余 pending 恰是该人看的低置信结论;信噪比列入长期观察项(Part D)。

结语 · 这样设计的好处(与代价)

把上面的设计选择合起来看,这套 Agent 的综合好处是:

1. 可托付——后台可恢复 + 幂等 + reclaim,让它能跑真实的长任务、扛崩溃重启,而不是一关页面就没。
2. 长期陪伴——双层记忆 + 自我改进闭环,用得越久越懂你,且人在环路防污染。
3. 安全可控——审批分级 + 角色最小权限 + 执行面刻意收窄 + 沙箱,把"Agent 乱来"的面收得很小。
4. 多人协作——群聊 topic 协调是多数 Agent 没有的能力。
5. 可干预——steer/deny 持久化让用户能真正改向、且改向不漂回。
6. 检索可信(v2)——中英双语并行扇出保覆盖,质量信号三道关(识别→拦引用→触发改写)保不被垃圾骗,[n] 引用保可溯源;每一层都有真实 query 的活体验证背书。
7. 研究知识复利(v3)——查过的论文与结论自动沉淀为带出处的 finding,跨会话可召回、开局自动预取、报告可复访;伪的标伪不删、错的可纠可追回、旧版本循链可查——"越查越强、越记越多"从愿景变成机制(A.12),且是对标调研确认的全行业空白能力。

换来的代价也清楚:不做编码 Agent 的活(无 shell/文件),plan-once 在探索性任务上不如纯 ReAct(refine 门补位后差距收窄但仍在),依赖外部 MAGI/E2B/DeepSeek/Tavily,状态机比"一把梭"复杂。

何时该选这套:要一个长期、可恢复、有记忆、研究知识越积越强、能群聊、可审批的对话陪伴/研究助理。何时不该:要一个改代码、跑 shell、操作文件系统的编码 Agent——那是 Claude Code 一类的主场。

诚实声明:本报告所有架构论断均对应真实源码(apps/api/src/lib/agent/ 等,正文附文件:行);评分为定性判断非基准跑分;局限与代价均如实列出,未夸大已完成度。