

Agent 端到端测试 Campaign 报告

Carl-Gustav-Jung 智能体 — 以「荣格心理学:INFP 性格」为旗舰真实问题

日期 2026-06-08 · 驱动方式 relay(Claude 当 LLM)· 真实工具(Tavily/E2B/FRED/Jina/OpenAlex)真数据

① 概述与目标

对整个 agent 项目做一轮真实端到端 campaign:用「用荣格认知功能理论讲清 INFP 性格」作旗舰,跨会话串起记忆弧,穷举工具与控制流,做前端设计一致性检查与安全探针,发现即修,产出本报告。

诚实边界: agent 的 LLM 由 relay(我,Claude)代笔,故工具选择认知是代笔、非测得;真正测得的是 agent 自身行为——执行机器、记忆子系统(蒸馏/召回/主动注入/时序失效/反思/升格)、控制流、前端与隔离。报告「效果」评的是系统有效性,非生产 LLM 回答质量。

② 测试环境与拓扑(可复现钉)

项	值
agent commit	3f8a8c6 (feat/agent-memory-enrich) + 本次修复 ac2475a
MAGI commit / 迁移	d9d1061 (feat/agent-memory-m4) / alembic head 057
隔离全栈	M4 MAGI(:8097,真 bge+jieba)· relay(:3934,v2 路由)· fresh app(:3923)
测试用户	jungtester(6a47331f) + victim2(隔离对照)
真实外部	Tavily/E2B/FRED/Jina/OpenAlex(.env 真 key)

③ 工具覆盖(19/19 生产工具;防假绿=输出内容断言)

工具	结果	证据/用途
search_web (Tavily)	ok	R1 真搜荣格/MBTI
wikipedia	ok	R1 概念背景
search_papers (OpenAlex)	ok	R1 学术支撑
run_python (E2B)	ok	stdout 『hello from e2b / sqrt16=4.0』真执行
get_economic_series (FRED)	ok	UNRATE 『Unemployment Rate』真观测
fetch_url (Jina)	ok	抓 Carl Jung 正文真内容
render_diagram / doc_export	ok	R5 功能栈图 + 分析文档 artifact
recall_memory	ok	R2 跨会话拉回 R1 fact(score 0.787)
magi_content_ingest	ok(审批)	审批 approve/deny 两态
ask_user	ok	暂停→resume
datetime_now / critique_last_answer	ok	探测/自检
document_reader / youtube_transcript	ok	PDF 解析 / 字幕
get_paper_citations / recall_step	ok	引用 / 重读步骤
magi_system_read	soft-fail	HTTP 404 优雅续跑(研究库非本测重点)
deep_research	Tier-2 延后	子 agent spawn 经 relay 需独立 plan

④ 旗舰记忆弧 R1-R6(全 PASS)— M2/M3/M4 端到端 live

轮	验证点	结果
R1 建立	distill 经真 run 边界写 MAGI 2 条带 sentiment(positive/neutral)	PASS
R2 跨会话召回	新 session;planner req 注入 <proactive_memory> 「INFP」 + recall_memory 拉回(0.787)	PASS
R3 改主意 INFP	reconcile judge supersede→旧 INFP fact valid_until 置位;recall 只返 INFP	PASS
R4a 反思	攒够 9 facts→reflection 触发→insight id=10 带 source_fragment_ids{3,5,6,9}	PASS
R4b 升格	面板 /promote→原生 memory_fragments(source=import)+ MAGI promoted_at;search 排除 promote 幕等	PASS
R5 产物	render_diagram + doc_export 生成 artifact	PASS
R6 中文 sparse	搜中间词「阴影」jieba 命中 id=9 居首(0.569)	PASS

⑤ 安全与隔离(最高价值)

prompt-injection 跨 owner — PASS: 建 victim2 + 私密「银行卡密码 SECRET-9931」;user1 发注入指令 + 恶意 plan 主动调 recall_memory(query 指向该密码)。结果:recall step 输出含 SECRET 0 次、最终回复泄漏 0 次——owner-lock(ctx.ownerId)在工具层拦死跨用户(对标 ADR §5.1 信任边界)。

⑥ 前端设计一致性(检查 UI 是否与设计一致,非仅渲染)

静态预检(对 zh-CN.ts)发现 2 处真漂移,并已修复:

漂移	设计来源	现象→修复
DRIFT-2(真 bug)	zh-CN.ts memoryReviewEmpty	审核屏空态硬编码「没有待审的记忆」≠ 设计「没有待审核的记忆」→ 已改对齐
DRIFT-1(潜在)	zh-CN brain.sections.memoryEpisodic	标题硬编码 → 已改用 zh.brain.sections.memoryEpisodic

修复:commit ac2475a,mobile tsc 干净。

运行时 Maestro 全流程 PASS(装 JDK 后解锁): 真驱动 启动→流浪猫大脑→流浪猫记忆→长期记忆审核;M4i UI 逐项与设计一致——U8 标题走 locale、U3 情感标签(消极/中性/积极三色)、U2 洞见徽章、U4「由 2 条合成」、U5 分栏(待审批准/拒绝·已批准升格)、U1 升格状态机:点「升格到核心」→ 变「已升格到核心记忆」;后端确认 MAGI promoted_at 置位 + 原生 memory_fragments 创建(UI 点按→后端→UI 闭环)。截图 m09/m10/m11。

⑦ 控制流 + 发现的问题与修复

控制流(全 PASS): approval 三态(approve→grant→执行;deny→replan→完成)· ask_user 暂停/resume · 中途 cancel(running→cancelled)。

已修问题: DRIFT-1/2 前端文案与设计对齐(commit ac2475a)。

候选 finding F-A(延后): plan 含未注册 toolName 时,run 无 step、status 永停 planning(>1min 无终态)——运行时缺防御性工具名校验。由 planner 幻造工具名触发(prompt 已禁止,真实 LLM 偶发)。建议 buildInitialPlan/dispatch 对未知工具 reject→fail/replan。中severity,核心改动延后。

⑧ 指标与结论

指标	值
阶段0 绿基线	agent 657 vitest + MAGI 30 pytest 全绿;campaign 后无回归
记忆弧	R1-R6 全 PASS(M2/M3/M4 live)
工具覆盖	19/19 生产工具(18 ok/soft-fail + deep_research Tier-2)
控制流	approval/ask_user/cancel 全 PASS
安全	prompt-injection 跨 owner 0 泄漏
前端	设计一致性查出并修复 2 漂移;运行时 Maestro 全流程 PASS(导航+审核屏 U1-U5/U8+升格状态机+后端闭环)
问题/修复	修复 2(DRIFT-1/2);候选 1(F-A 卡 planning,延后)

成本指标	relay 下 token/cost 为 moot(非生产计价);per-run steps 1-5,工具真延迟正常
------	--

结论: agent 系统(规划执行机器、记忆子系统含 M4 全部增强、控制流、owner 隔离、产物工具链)在真实端到端环境下整体有效;前端与设计存在 2 处文案漂移已修。relay 限制下未测生产 LLM 的工具选择认知与回答质量。

附:前端 Maestro 截图(运行时设计一致性证据)

待审(消极标签+批准/拒绝)	已批准(洞见徽章/情感/由2条合成/升格)	升格后(→已升格到核心记忆)
07:55 长期记忆审核 待审 已批准 消极 用户最近压力较大 置信 0.60 · 2026-06-07 批准 拒绝	07:56 长期记忆审核 待审 已批准 洞见 积极 用户是价值观与想象力驱动的内倾型,核心诉求自我成长 置信 0.92 · 2026-06-07 · 由 2 条合成 升格到核心 中性 用户在学习荣格的认知功能理论 置信 0.90 · 2026-06-07 升格到核心 积极 用户认为自己是 INFP 人格类型 置信 0.90 · 2026-06-07 升格到核心	07:56 长期记忆审核 待审 已批准 洞见 积极 用户是价值观与想象力驱动的内倾型,核心诉求自我成长 置信 0.92 · 2026-06-07 · 由 2 条合成 已升格到核心记忆 中性 用户在学习荣格的认知功能理论 置信 0.90 · 2026-06-07 升格到核心 积极 用户认为自己是 INFP 人格类型 置信 0.90 · 2026-06-07 升格到核心